

Boyd 的凸优化

刘大爷

May 17, 2025

我去年九月时问起凸集是否定义在向量空间上，未得到有效答复。现看夏道行忆起前事。凸集是泛函分析中常用的概念，在线性空间上半范数的研究需要凸集。对于线性空间中任意半范数 $p(x)$ ，集 $\{x|p(x) \leq 1\}$ 就是一个凸集，称它为范数 p 所导出的凸集。总之具有许多性质，但我不知道。

0.1 凸集

0.1.1 仿射集合和凸集

1. 仿射集合。下面的 x_1, x_2 都是任意的（在其域中）

- 直线与线段
- 集合是仿射的，如果过集合中任意两个不同的直线仍在集合中，即：

$$\theta x_1 + (1 - \theta)x_2 \in C \quad (1)$$

- 仿射组合如果 $\sum_k \theta_k x_k \in C, \sum_k \theta_k = 1$ ，则称为 $\{x_k\}$ 的仿射组合。
- 子空间。仿射集合 C 的子空间为：

$$V = c - x_0 = \{x - x_0 | x \in C\} \quad (2)$$

易证其对于加法和数乘封闭。

- 仿射包：

$$\text{aff}C = \{\theta_1 x_1 + \dots + \theta_k x_k | x_1, \dots, x_k \in C, \theta_1 + \dots + \theta_k = 1\} \quad (3)$$

仿射包是包含 C 的最小仿射集合

- 仿射维数与相对内部因定义不够清晰，暂时跳过。

2. 凸集

- 定义

$$\theta x_1 + (1 - \theta)x_2 \in C, \theta \in [0, 1] \quad (4)$$

- 凸组合

如果 $\sum_k \theta_k x_k \in C, \sum_k \theta_k = 1, \theta_k > 0$ ，则称为 $\{x_k\}$ 的凸组合。一个集合是凸集等价于集合包含其中所有点的凸组合。

- 凸包:

$$\text{conv}C = \{\theta_1 x_1 + \dots + \theta_k x_k | x_1, \dots, x_k \in C, \theta_1 + \dots + \theta_k = 1, \theta_k \geq 0\} \quad (5)$$

凸是包含 C 的最小凸集合。

3. 锥

- 凸锥定义

$$\theta_1 x_1 + \theta_2 x_2 \in C, \theta x \in C, \theta \geq 0 \quad (6)$$

锥不一定是凸的。上述定义是针对凸锥的充要条件。

- 锥组合

如果 $\sum_k \theta_k x_k \in C, \theta_k \geq 0$, 则称为 $\{x_k\}$ 的锥组合。一个集合是凸锥等价于集合包含其中所有点的锥组合。

- 集合 C 的锥包是其中所有元素所有锥组合的集合, 是包含 C 的最小凸锥。因此可以说, 锥包是凸锥, 锥包一定是凸的。

0.1.2 重要例子

在此前需要明确一些概念。就一般而言, 仿射集合是定义在向量空间上的, 但是仿射空间不一定具有加法单位元和逆元, 因此更多是一个集合而非向量空间。由仿射集合定义在向量空间上, 因此其性质在欧几里得空间也成立; 子空间定义在向量空间上, 因此也满足仿射集合的性质。

1. 重要例子。直线经过零点, 具有加法单位元, 才符合子空间的性质。
2. 超平面是集合:

$$\{x | a^T x = b\} \quad (7)$$

上述定义等价于

$$\begin{aligned} \{x | a^T (x - x_0) = 0\} \\ \{x | a^T (x - x_0) = 0\} &= x_0 + a^\perp \\ \{v | a^T v = 0\} &= a^\perp \end{aligned}$$

半空间为上述取 “ \leq ”。

3. 欧几里得球和椭球（感觉太 trivial 了）

$$\epsilon = \{x + Au \mid \|u\|_2 \leq 1\} \quad (8)$$

显然 $A = r$ 时为球的定义。一般来说， A 对称半正定，但当是奇异时称为退化的。椭球也有如此定义：

$$\{x \mid (x - x_c)^T P^{-1} (x - x_c) \leq 1\}$$

其中 P 一般是对称正定的

4. 范数锥

$$C = \{(x, t) \mid \|x\| \leq t\} \quad (9)$$

既然是范数，满足范数的运算定理。范数锥和范数球是凸的。

5. 多面体

$$\mathcal{P} = \{x \mid a_j^T x \leq b, c_j^T x = d_j\} \quad (10)$$

注意到等式约束 $c_j^T x = d_j$ 可能是冗余的。

6. 单纯形（不考）

$$C = \text{conv}\{v_i\} = \left\{ \sum_{i=0}^k \theta_i v_i \mid \theta_i \geq 0, 1^T \theta = 1 \right\} \quad (11)$$

7. 半正定锥

$$S^n = \{X \in R^{n \times n} \mid X = X^T\} \quad (12)$$

此为对称矩阵。半正定、正定锥同理。显然半正定矩阵的集合 S_+^n 是凸锥

0.1.3 保凸运算

1. 交集。凸集的交集

2. 仿射函数。一个函数是凸的，如果其为一个线性函数和一个常数的和，即为 $f(x) = Ax + b$ 。其中 $f : \mathbf{R}^n \rightarrow \mathbf{R}^m$ 。因为仿射集定义在向量空间上，因此仿射集的数乘和加法是保凸的。向量空间是仿射的，任何仿射集都是向量空间的子空间，而因此对于 $x \in S_1, y \in S_2, x + y \in V$ ，仍是仿射的。直积（有序对）和部分和是仿射的，但直和是否是仿射的有待商榷。如果 S_1, S_2 是无关的，则两仿射集的和亦为直和。仿射变换有：伸缩、平移、投影、集合的和、直积、部分和

3. 线性分式与透视函数。比仿射函数更普遍

- 透视函数

$$P(z, t) = z/t \quad (13)$$

没有对定义域有凸的要求。

- 线性分式函数

$$f(x) = (Ax + b)/(c^T x + d) \quad \text{dom} f = \{x | c^T x + d > 0\} \quad (14)$$

由透视函数和仿射函数复合而成: $g: \mathbf{R}^n \rightarrow \mathbf{R}^{m+1}$, $P: \mathbf{R}^{m+1} \rightarrow \mathbf{R}^m$, $f = P \circ g: \mathbf{R}^n \rightarrow \mathbf{R}^m$

比如, 条件概率。显然 A 与 c 都可为 0。

0.1.4 广义不等式

正常锥

1. 正常锥的定义

$$N_c(x) = \{v \in \mathbf{R}^n : (v, y - x) \leq 0, \forall y \in C\} \quad (15)$$

其中 C 是凸集, v 表示指向凸集外部的向量。 x 必须在凸集 C 中。

2. 正常锥的性质:

凸、闭、实 (非空内部, 注线不是实的)、尖的

3. 正常锥定义偏序关系:

$$x \preceq_K y \iff y - x \in K$$

广义不等式

严格的广义不等式许多性质和一般的广义不等式类似

1. 对于加法保序

$$x + u \preceq_K y + v$$

2. 具有传递性

3. 非负数乘保序

4. 自反的 (严格的广义不等式不满足)

$$x \preceq_K x$$

关于正常锥和广义不等式有两个典型例子: 非负象限和半正定锥。很 trivial 吧。

最小元与极小元

1. 最小元 x

$$x \preceq_K y \quad y \in S$$

2. 极小元 x

$$y \preceq_k x \quad y \in S, y = x$$

0.1.5 分离与支撑超平面

1. 超平面 $\{x | a^T x = b\}$ 为集合 C 和 D 的分离超平面，若两者为凸集且交集为空集
2. 如果 $a \neq 0$ 且对任意 $x \in C$ 满足 $a^T x \leq a^T x_0$ ，则称超平面 $\{x | a^T x = a^T x_0\}$ 为集合 C 在 x_0 处支撑超平面

对偶锥

令 K 是一个锥，集合

$$K^* = \{y | x^T y \geq 0, \forall x \in K\}$$

称为 K 的对偶锥，即使 K 不是凸锥

Proof. 若在实向量空间上 $y^T x$ 等价于内积（即满足锥性），因此

$$\begin{aligned} \theta y_1^T x + (1 - \theta) y_2^T x &= \theta(y_1, x) + (1 - \theta)(y_2, x) \\ &= (\theta y_1 + (1 - \theta) y_2, x) \\ &= (y, x) \end{aligned}$$

凸性得证

□

更严谨的说法，对偶锥是一系列过原点的超平面的交

帕累托最优制造

1. 生成集合 \mathbf{P} 上的极小元对应的制造方法称为帕累托最优的， P 的极小元构成的集合为帕累托最优制造前沿（什么玩意儿）

0.2 凸函数

0.2.1 基本性质和例子

1. 凸函数

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) \quad (16)$$

dom f must be convex set. 如果不等号成立，则为严格的。注意, $\theta \in (0, 1), x \neq y$ 时为严格凸的（凸的只需 $\theta \in [0, 1]$ ）

2. 仿射函数既凸又凹

3. 函数是凸的，当且仅当其在与其定义域相交的任何直线上都是凸的。这个命题等价于当且仅当对于任意 $x \in \text{dom } f$ 和任意向量 v ，函数 $g(t) = f(x + tv)$ 是凸的 ($\{t | x + tv \in \text{dom } f\}$)

4. 扩充实值函数

5. 一阶条件（陈述是充要的），如果 $\text{dom } f$ 是凸集且有

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) \quad (17)$$

Proof.

$$\begin{aligned} \nabla f(x)^T &= \frac{f(x + \theta(y - x)) - f(x)}{\theta(y - x)} \\ f(x + \theta(y - x)) &= f(x) + \theta \nabla f(x)^T(y - x) \end{aligned}$$

根据凸函数的定义可得：

$$\theta f(y) + (1 - \theta)f(x) \geq f(\theta y + (1 - \theta)x)$$

则有：

$$\begin{aligned} \theta f(y) + (1 - \theta)f(x) &\geq f(x) + \theta \nabla f(x)^T(y - x) \\ f(y) &\geq f(x) + \nabla f(x)^T(y - x) \end{aligned}$$

□

注意 $\nabla f(x)$ 是列向量。严格凸的则不等式成立

6. 二阶条件（是充要的）， $\forall x \in \text{dom} f$ （ $\text{dom} f$ 是开集）有

$$\nabla^2 f(x) \succeq 0 \quad (18)$$

其中 $\nabla^2 f(x)_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$ 。注意，严格凸函数推出二阶条件是充分不必要的。

7. 凸函数实例（不常见的）

- 负熵 $x \log x$. 二阶导严格凸，二阶充要条件证明其。
- 范数. 都是凸的

Proof. 由三角不等式

$$\|x + y\| \leq \|x\| + \|y\|$$

和齐次性可得

$$f(\theta x + (1 - \theta)y) \leq f(\theta x) + f((1 - \theta)y) = \theta f(x) + (1 - \theta)f(y)$$

□

- 仿射函数既凸又凹
- 最大值函数是凸的

Proof. 由

$$\theta x + (1 - \theta)y \leq \theta x^* + (1 - \theta)y^*$$

（其中 $x^* = \max\{x_n\}, y^* = \max\{y_n^*\}$ ）可得

$$\begin{aligned} \theta \max\{x_1, \dots, x_n\} + (1 - \theta) \max\{y_1, \dots, y_n\} &= \max\{\theta x_1, \dots, \theta x_n\} + \max\{(1 - \theta)y_1, \dots, (1 - \theta)y_n\} \\ &\geq \max\{\theta x_1 + (1 - \theta)y_1, \dots, \theta x_n + (1 - \theta)y_n\} \end{aligned}$$

□

- 指数和的对数，可视为最大值函数的可微近似
- 最小二乘，线性分式函数都是凸函数（皆用二阶条件）

8. 下水平集。定义：

$$C_\alpha = \{x \in \text{dom} f | f(x) \leq \alpha\} \quad (19)$$

凸函数的下水平集合仍是凸集

Proof. $x, y \in C_\alpha$, 有 $f(x) \leq \alpha, f(y) \leq \alpha$, 则 $f(\theta x + (1 - \theta)y) \leq \alpha$, 即 $\theta x + (1 - \theta)y \in C_\alpha$ \square

反之不成立, 比如 $-e^x$ 。对上水平集 (凹函数) 同理。强拟凸函数的任一下水平集都是凸集。

9. 上境图是 \mathbb{R}^{n+1} 的一个子集。定义:

$$\text{epi} f = \{(x, t) | x \in \text{dom} f, f(x) \leq t\} \quad (20)$$

几何视角: 法向量为 $(\nabla f(x), -1)$ 的超平面在边界的 $(x, f(x))$ 支撑 $\text{epi} f$, 其中 (y, t) 是半空间中的点。写成超平面形式。

10. **Jensen** 不等式。凸函数的定义即为基本不等式。若存在 k 个点满足 (凸组合, $\sum \theta_i = 1$), 则有:

$$f(\theta_1 x_1 + \dots + \theta_k x_k) \leq \theta_1 f(x_1) + \dots + \theta_k f(x_k) \quad (21)$$

或有:

$$f(\mathbf{E}x) \leq \mathbf{E}f(x) \quad (22)$$

利用对数函数可证明算数-几何平均不等式

(a) 算术-几何平均不等式。真的易证

$$\sqrt{ab} \leq (a + b)/2$$

(b) **Holder** 不等式: 对于 $\frac{1}{p} + \frac{1}{q} = 1$ 有

$$\langle x, y \rangle \leq \|x\|_p \|y\|_q$$

0.2.2 保凸运算

验证保凸运算

1. 定义
2. 一二阶条件
3. 上境图

下述保凸运算的前提都是凸函数

1. 非负加权求和。凸函数的集合本身是一个凸锥。

$$f = \theta_1 f_1 + \dots + \theta_n f_n$$

2. 复合仿射映射

$$g(x) = f(Ax + b) \quad (23)$$

3. 逐点最大和逐点上确界

$$f(x) = \max\{f_1(x), f_2(x)\} \quad (24)$$

Proof.

$$\begin{aligned} f(\theta x + (1 - \theta)y) &= \max\{f_1(\theta x + (1 - \theta)y), f_2(\theta x + (1 - \theta)y)\} \\ &\leq \max\{\theta f_1(x) + (1 - \theta)f_1(y), \theta f_2(x) + (1 - \theta)f_2(y)\} \\ &\leq \theta \max\{f_1(x), f_2(x)\} + (1 - \theta) \max\{f_1(y), f_2(y)\} \text{ (注意, 为什么是 } \leq \text{)} \\ &= \theta f(x) + (1 - \theta)f(y) \end{aligned}$$

□

4. 复合。 $f = h \circ g$, 若 f 是凸的, h 和 g 必须满足的条件。

标量复合

$$f''(x) = h''(g(x))g'(x)^2 + h'(g(x))g''(x)$$

下述即使对 h 的扩充实值函数依然成立

- if h is convex and non-decreasing and g is convex, f is convex
- if h is convex and non-increasing, g is concave, f is convex
- if h is concave and non-decreasing, g is concave, f is concave
- if h is concave and non-increasing, g is convex, f is concave

矢量复合, $g(x)$ is vector

$$f(x) = g'(x)^T \nabla^2 h(g(x)) g'(x) + \nabla h(g(x))^T g''(x)$$

就是有四种情况。如果 g_i 是凸函数, h 是凸函数且在每维单调非减, 则凸; 如果 g_i 是凸函数, h 是凹函数且在每维单调非减, 则凹; 如果 g_i 是凹函数, h 是凸函数且在每维单调非增, 则凸; 如果 g_i 是凹函数, h 是凸函数且在每维单调非减, 则凹

5. 最小化。 $f(x, y)$ 是凸函数。

$$g(x) = \inf_{y \in C} f(x, y) \quad (25)$$

Proof.

$$\begin{aligned} g(\theta x_1 + (1 - \theta)x_2) &= \inf f(\theta x_1 + (1 - \theta)x_2, y) \\ &\leq f(\theta x_1 + (1 - \theta)x_2, \theta y_1 + (1 - \theta)y_2) \\ &\leq \theta f(x_1, y_1) + (1 - \theta)f(x_2, y_2) \\ &\leq \theta g(x_1) + (1 - \theta)g(x_2) + \epsilon \end{aligned}$$

□

6. 透视函数

$$g(x, t) = tf(x/t) \quad (26)$$

负对数的透视函数称为相对熵，是凸的。

0.2.3 共轭函数

1. 共轭函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，无论是否为凸函数， f^* 是凸函数因为其为逐点上确界

$$f^*(y) = \sup_{x \in \text{dom} f} (\langle y, x \rangle - f(x)) \quad (27)$$

Exempl

2. 仿射函数 $f^*(y) = yx - ax - b$ 有界当且仅当 $y = a$, so $\text{dom} f = a$

3. 负对数. $f(x) = -\log x$, 仅在 $x = -1/y$ 有上界

有一些细节，主要是在不同区间需要讨论，从而确定 $\text{dom} f^*$. 注意，判断方式是对 x 求导而非

基本性质。

• Fenchel 不等式

$$f(x) + f(y)^* \geq x^T y \quad (28)$$

因为共轭函数定义在实数域上，因此 $y^T x = x^T y = \langle x, y \rangle$.

- 共轭的共轭

$$f^{**}(x) = \sup_{y \in \mathbb{R}^n} \{y^T x - f^*(y)\} \quad (29)$$

由 Fenchel 不等式可得,

$$f(x) \geq x^T y - f^*(y) = f^{**}(x)$$

若 $f(x)$ 是真的闭凸函数, 那么 $f(x) = f^{**}(x)$ 。证明如下 (为自己而已):

Proof. 取向量 $(x, \gamma) \in \text{epi} f^{**}$, $(y, \omega) \in \text{epi} f^*$ 且 $(x, \gamma) \notin \text{epi} f$, 则对于 $\text{epi} f$ 的支持一超平面, 其法向量为 (α, β) (因为对应于上境图, 其中 α, x 为 n 维实数空间中的向量) 有:

$$(\alpha, \beta)^T (y, \omega) < b < (\alpha, \beta)^T (x, \gamma)$$

即

$$\alpha^T y + \beta \omega < \alpha^T x + \beta \gamma$$

由于 ω, γ 为标量, 可以取任意值, 而由 $f > f^{**}$ 可得存在 $\omega > \gamma$ 。因此取 β 为负 (例如-1) 时上式成立:

$$\alpha^T y - \omega < \alpha^T x - \gamma$$

即

$$\begin{aligned} \alpha^T y - f(y) &< \alpha^T x - f^{**}(x) \\ f^*(\alpha) &< \alpha^T x - f^{**}(x) \end{aligned}$$

由于共轭的共轭满足 Fenchel 不等式, 即

$$f^*(y) + f^{**}(x) \geq y^T x$$

因此上式与此矛盾, 不存在这样的向量 (x, γ) , 也即 $(x, \gamma) \in \text{epi} f$, 则有 $f(x) \leq f^{**}(x)$, 又由 Fenchel 不等式可得, $f(x) = f^{**}(x)$ \square

- 伸缩变换和复合仿射变换. $g(x) = af(x) + b$, 则有:

$$g^*(y) = af^*(y/a) - b \quad (30)$$

Proof.

$$\begin{aligned}
 g^*(x) &= \sup\{y^T x - g(x)\} \\
 &= \sup\{y^T x - af(x) - b\} \\
 &= \sup\{y^T x - af(x)\} - b \\
 &= a \sup\left\{\frac{y^T}{a} x - f(x)\right\} - b \\
 &= af^*(y/a) - b
 \end{aligned}$$

□

$g(x) = f(Ax + b)$, 则有:

$$g^*(y) = f^*(A^{-T}y) - b^T A^{-T}y \quad (31)$$

Proof.

$$\begin{aligned}
 g^*(x) &= \sup\{y^T x - g(x)\} \\
 &= \sup\{y^T x - f(Ax + b)\}
 \end{aligned}$$

令 $Ax + b = u$, 则 $x = A^{-1}(u - b)$, 有:

$$\begin{aligned}
 g^*(x) &= \sup\{y^T A^{-1}(u - b) - f(u)\} \\
 &= \sup\{y^T A^{-1}u - f(u)\} - y^T A^{-1}b = f^*(A^{-T}y) - y^T A^{-1}b
 \end{aligned}$$

□

• 独立函数的和

$$f^*(w, z) = f_1^*(w) + f_2^*(z) \quad (32)$$

0.2.4 拟凸函数

1. 定义与例子. 定义域及其所有下水平集

$$S_\alpha = \{x \in \text{dom} f \mid f(x) \leq \alpha\} \quad (33)$$

都是凸集。如果函数拟凸又拟凹, 那么是拟线性函数, 即 $\{x \mid f(x) = \alpha\}$ 和定义域是凸集。

对数函数拟线性, $f(x_1, x_2) = x_1 x_2$ (定义域正实数) 是拟凹函数, 线性分式函数拟线性函数, 上取整函数是拟凸函数。

2. 基本性质, 充要条件

$$f(\theta x + (1 - \theta)y) \leq \max\{f(x), f(y)\} \quad (34)$$

3. 如果函数是拟凸的, 等价于满足其中之一 (i) 非减 (ii) 非增 (iii) 全局最小点左右恒非减或非增

0.2.5 对数凸与对数凹

1. 定义, $\log f$ 是凸或凹的, 则是对数凸或对数凹的。如果对数凹的, 有:

$$f(\theta x + (1 - \theta)y) \geq f(x)^\theta f(y)^{1-\theta} \quad (35)$$

2. 仿射函数是对数凹函数, 指数函数既是对数凸函数也是对数凹函数

0.3 凸优化问题

0.3.1 优化问题

基本术语

方程组为约束，相应的函数为约束函数。定义域为：

$$\mathcal{D} = \bigcap_{i=1}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$$

可行点的集合为可行集。 $p^* = \inf\{f_0(x)\}$ 若 $p^* = \infty$ 则不可行，若 $p^* = -\infty$ 则无下界。若 $f_0(x^*) = p^*$ 则 x^* 为最优点，存在则最优值可达，不存在则不可达（常为无下界时）。满足 $f_0(x) \leq p^* + \epsilon$ 的可行解为 ϵ 次优。局部最优解：

$$f_0(x) = \inf\{f_0(z) \mid \|z - x\|_2 \leq R\}$$

局部最优是优化问题的解

等价问题

此处有诸多疑难，建议先跳过

1. 变量变换是等价问题。若 $\phi : z \rightarrow x$ 是双射，则 $f_0(z)$ 由变量代换得到。即为 $\tilde{f}_i(z) = f_i(\phi(z))$
2. 目标函数和约束函数的变换。此处 $\phi : \mathbf{R} \rightarrow \mathbf{R} \tilde{f}_i(x) = \phi_i(f_i(x))$
3. 松弛变量。
4. 消除等式约束。所谓消除等式约束，就是定义这样一个映射 $\phi : z \rightarrow x$ 使得 $\{0\} \subset \text{null} \phi$ 。以线性等式约束 $Ax = b$ 就是将通解（如果存在）代入优化问题：
 $x = Fz + x_0$
5. 引入等式约束。引入 $y = Ax + b$
6. 优化部分变量。由 $\inf_{x,y} f(x,y) = \inf_x \tilde{f}(x)$
7. 上境图

$$\begin{array}{ll} \min & t \\ \text{s.t} & f_0(x) \leq t \end{array}$$

8. 隐式与显式约束。拿衣舞。

0.3.2 凸优化

标准形式

$$\begin{aligned} & \min f_0(x) \\ & \text{subject to } f_i(x) \leq 0 \\ & a_i^T x = b_i \end{aligned}$$

f_i 必须为凸函数，即满足：1) 目标函数是凸的；2) 不等式约束函数是凸的；3) 等式约束函数是仿射的。因此可行集是凸的，由 m 个下水平集和 p 个超平面的交集组成。

上述为凸优化问题的标准形式，实际情况下，许多不是标准形式。

0.3.3 局部最优与全局最优

凸优化问题的局部最优同时也是全局最优。这个理论乍一看很显然，但实际上也很显然，用分析的语言来描述。

$$f_o(x^*) = \inf\{f_0(x) \mid |x - x^*| < \epsilon\}$$

如果 x^* 仅为局部最优而非全局最优的，那么存在一个点 y 为最优的。由凸函数的性质可得，

$$x = (1 - \theta)x^* + \theta y$$

$$f(x) \leq (1 - \theta)f(x^*) + \theta f(y)$$

取 $\theta = \frac{\epsilon}{2|y - x^*|}$ ，将其代入可得：

$$\begin{aligned} x &= x^* + \theta(y - x^*) \\ &= x^* + \frac{\epsilon}{2} \end{aligned}$$

故 x 又在局部中，和凸性矛盾。证毕。显然这个在度量空间也成立，除非凸性在度量空间不成立。

可微函数的最优性准则

如果 x 是最优解，当且仅当：

$$\nabla f_0(x)^T(y - x) \geq 0 \quad \forall x, y \in X \quad (36)$$

Think of 凌青。注意证明同样采用了上面的反正-构造方法。

1. 无约束问题的最优解充要条件为：

$$\nabla f_0(x) = 0$$

思考一下无约束二次规划解的三种情况（其实就是可逆性）

2. 只含等式约束的问题。这个比较复杂，当时提及了实向量空间上的伴随算子的矩阵等价于算子的转置，因此这个证明是容易的。不过还要再看，其他部分的论述很不清晰。建议学习凌青的证明。 $f_0(x)$ 的梯度方向与 $Ax + b$ 垂直，也即 $Ax + b$ 与 $f_0(x)$ 相切

$$\nabla f_0(x)^T \perp Av$$

或

$$\nabla f_0(x) + A^T v = 0$$

3. 非负象限中的极小化。由 $x \succeq 0, \forall y \in X$ 与最优性准则可得 $-\nabla f_0(x)^T x \geq 0$ 。结论就是

$$\sum \nabla f_0(x)_i x_i = 0$$

实际上是互补性。

等价的凸问题

1. 消除等式约束。这个要看一下板书
2. 引入等式约束。比如原 $x = Ay + b$ 辄加入此约束
3. 松弛变量。 f_i 必须是仿射的。
4. 上境图形式。新的目标函数 t 和约束函数 $f_0(x) - t$
5. 极小化部分变量

0.3.4 线性规划问题

目标函数和约束函数都必须是仿射的。具有如下形式：

$$\begin{aligned} \min \quad & c^T x + d \\ \text{s.t.} \quad & Gx \preceq h \\ & Ax = b \end{aligned}$$

可行集是多面体。

1. 标准形式

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & x \succeq 0 \end{aligned}$$

2. 没有等式约束，辄为不等式形式线性规划

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax \preceq b \end{aligned}$$

3. 转化为标准形，即加入松弛变量，都是等式约束。后面的例子太多，等十六周和做题遇到才看。

4. 清楚分片线性极小化采用上境图转化。分片线性极小化：

$$f(x) = \max_{i=1 \dots m} (a_i^T x + b_i)$$

构造为上境图为：

$$\begin{aligned} \min \quad & t \\ \text{s.t.} \quad & a_i^T x + b_i \leq t \end{aligned}$$

0.3.5 二次优化问题

二次规划

$$\begin{aligned} \min \quad & (1/2)x^T P x + q^T x + r \\ \text{s.t.} \quad & Gx \preceq h \\ & Ax = b \end{aligned}$$

注意到 P 是对称半正定的矩阵。上述为 **QP**。如果不等式约束也是凸二次型，辄称为 **QCQP**。

典型例子

1. 最小二乘及回归。约束为 $l_i \leq x_i \leq u_i$
2. 多面体距离。 $\|x_1 - x_2\|_2^2$ 若最优解为 \circ 则相交，无可性解多面体为空

二阶锥规划

此类问题为 SOCP

$$\begin{aligned} \min \quad & f^T x \\ \text{s.t.} \quad & \|A_i x + b_i\|_2 \preceq c_i^T x + d_i \\ & Fx = g \end{aligned}$$

显然，当 $c_i = 0$ 是等同于 QCQP。

1. 鲁棒线性规划。约束条件

$$\sup\{a_i^T x \mid a_i \in \epsilon_i\} = \bar{a}_i^T x + \|P_i^T x\|_2 \leq b_i$$

0.4 对偶

0.4.1 Lagrange 函数的定义

优化问题是标准形式的，但不要求是凸的。**Lagrange** 函数用于将原始优化问题的目标函数与约束结合，形式如下：

$$L(x, \lambda, \nu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \nu_j h_j(x),$$

其中：

- $f(x)$ 是目标函数；
- $g_i(x) \leq 0$ 是不等式约束；
- $h_j(x) = 0$ 是等式约束；
- $\lambda_i \geq 0$ 是与不等式约束相关的拉格朗日乘子；
- $\nu_j \in \mathbb{R}$ 是与等式约束相关的拉格朗日乘子。

0.4.2 Lagrange 对偶函数的定义

对偶函数是通过最小化 Lagrange 函数 $L(x, \lambda, \nu)$ （对 x 变量）而得：

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu).$$

其中：

- $g(\lambda, \nu)$ 是拉格朗日对偶函数；
- \inf_x 表示在所有 x 上取下确界。
- 称 $\lambda \succeq 0, (\lambda, \nu) \in \text{dom} g$ 的 (λ, ν) 是对偶可行的

0.4.3 性质

(1) 对偶性 (Weak Duality)

对于任何 $\lambda \geq 0$ 和任意 ν ，都有：

$$g(\lambda, \nu) \leq f^*,$$

其中 f^* 是原始优化问题的最优值。即有：

$$\begin{aligned} g(\lambda, v) &= \inf(f_0(x) + \lambda^T(Ax - b) + v^T(Cx - d)) \\ &= -b^T\lambda - d^Tv - \inf(f_0(x) + (A^T\lambda + C^Tv)^Tx) \\ &= -b^T\lambda - d^Tv - f_0^*(-(A^T\lambda + C^Tv)^Tx) \end{aligned}$$

注意为负是因为虽然 $\langle y, x \rangle$ 是正的，但是 $f_0(x)$ 前是负的。试求熵的最大化问题

强对偶性 (Strong Duality)

若原始优化问题满足一定条件（如凸优化问题满足 Slater 条件），则有：

$$\sup_{\lambda \geq 0, \nu} g(\lambda, \nu) = f^*.$$

凸性

Lagrange 对偶函数 $g(\lambda, \nu)$ 是关于 λ 和 ν 的凹函数，即使原始问题不是凸优化问题。

0.4.4 Lagrange 对偶问题

定义：对偶问题是指通过最大化对偶函数 $g(\lambda, \nu)$ 得到：

$$\sup_{\lambda \geq 0, \nu} g(\lambda, \nu).$$

性质：

- 对偶问题是一个凸优化问题，即使原始问题不是凸的。
- 解对偶问题时，需满足 KKT 条件以保证解的可行性和最优性。
- 不等式和等式约束的线性规划的对偶函数是等价的

弱对偶性：

- $d^* \leq p^*$ 恒成立，无论原问题是否为凸问题，也无论 d^*, p^* 是否无限
- 原问题无下界，对偶问题不可行；对偶问题无上界，原问题不可行
- 对偶间隙: $p^* - d^*$

0.4.5 Slater 条件与强对偶性

强对偶性

对偶间隙为零则成立。若原问题是凸问题，那么强对偶性通常成立

Slater 条件

Slater 条件是凸优化中特殊的一种可行性条件，描述优化问题的强对偶性是否成立。对于问题：

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = 1, 2, \dots, m, \\ & h_j(x) = 0, \quad j = 1, 2, \dots, p, \end{aligned}$$

当目标函数 $f(x)$ 和所有约束 $g_i(x)$ 是凸函数，等式约束 $h_j(x)$ 是仿射函数时，Slater 条件要求存在一个严格可行解 x ，使得：

$$g_i(x) < 0, \quad i = 1, 2, \dots, m, \quad h_j(x) = 0, \quad j = 1, 2, \dots, p.$$

1. 定义

互补松弛性是 KKT 条件中的一个重要部分，描述了不等式约束的松弛与其拉格朗日乘子的关系。具体地：

$$\lambda_i g_i(x) = 0, \quad \forall i = 1, \dots, m,$$

其中：

- $\lambda_i \geq 0$ 是不等式约束 $g_i(x) \leq 0$ 的拉格朗日乘子；
- $g_i(x) \leq 0$ 是约束条件。

0.4.6 互补松弛性

- **必要性：**若 x^* 是原问题的最优解，且强对偶性成立，则互补松弛性是必要的。
- **直观意义：**互补松弛性表示，当一个不等式约束是活跃的（即 $g_i(x^*) = 0$ ）时，其对应的拉格朗日乘子 λ_i 可以是正值；当约束不活跃时（即 $g_i(x^*) < 0$ ），则 $\lambda_i = 0$ 。
- **在凸优化中的充分性：**对于凸优化问题，互补松弛性与其他 KKT 条件一起是充分条件。

0.4.7 KKT 条件的定义

对于一个带约束的优化问题：

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = 1, 2, \dots, m, \\ & h_j(x) = 0, \quad j = 1, 2, \dots, p, \end{aligned}$$

如果 $f(x)$ 和所有 $g_i(x)$ 是可微函数，KKT 条件包括以下几个部分：

1. 可行性条件：

$$g_i(x^*) \leq 0, \quad i = 1, 2, \dots, m, \quad h_j(x^*) = 0, \quad j = 1, 2, \dots, p.$$

2. 拉格朗日条件：存在拉格朗日乘子 $\lambda_i \geq 0$ 和 ν_j ，使得：

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \nu_j \nabla h_j(x^*) = 0.$$

3. 互补松弛条件：

$$\lambda_i g_i(x^*) = 0, \quad i = 1, 2, \dots, m.$$

4. 非负性条件：

$$\lambda_i \geq 0, \quad i = 1, 2, \dots, m.$$

0.4.8 KKT 条件与 Slater 条件的区别

1. 适用范围：

- KKT 条件适用于一般优化问题，包括非凸优化问题。
- Slater 条件主要用于凸优化问题。

2. 目标函数要求：

- KKT 条件不要求目标函数必须是凸函数。
- Slater 条件要求目标函数和不等式约束函数是凸函数。

3. 对偶性关系：

- KKT 条件是最优性条件，与目标函数的凸性无关。

- Slater 条件保证强对偶性，即原问题的最优值等于对偶问题的最优值。

4. 可行性要求：

- KKT 条件要求只需满足一般可行性条件。任意满足 KKT 条件的点分别是原问题、对偶问题的最优解
- Slater 条件要求存在一个严格可行解。

0.5 优化方法

0.5.1 无约束优化问题

求解方法

1. 首先要二次可微凸函数，因此最优点满足：

$$\nabla f(x^*) = 0$$

2. 极小化点列

$$f(x^{(k)}) \rightarrow P^*$$

当 $f(x^{(k)}) - p^* \leq \epsilon$ 时停止

例子

1. 二次凸优化

$$x^* = -P^{-1}q$$

如果无解则优化问题无下界。当是最小二乘时，有 $A^T A x^* = A^T b$

2. 无约束几何规划形如 $f(x) = \log(\sum \exp(a^T x_i + b_i))$ 没有解析解，只能采用迭代算法。

0.5.2 下降方法

优化点列：

$$x^{(k+1)} = x^{(k)} + t^{(k)} \Delta x^{(k)}$$

Δx 为搜索方向。 $f(x^{(k)})$ 给出下水平集 S ，因此屡次迭代在缩小这个集合，或皆处于 S 中。搜索方向必须满足：

$$\langle \nabla f(x^{(k)})^T, \Delta x^{(k)} \rangle < 0$$

和梯度方向的夹角必须是钝角，此类方向为下降方向。

通用下降方法

通用下降方法。 t 决定从直线 $x + t\Delta x$ 上某点开始下一步迭代，停止时 $\|\nabla f(x)\|_2 \leq \epsilon$

0.5.3 精确直线搜索 (Exact Line Search)

定义：在优化中，精确直线搜索是指沿给定方向 d_k 寻找一个步长 α_k ，使得：

$$\alpha_k = \arg \min_{\alpha > 0} f(x_k + \alpha d_k).$$

流程：

1. 确定当前点 x_k 和搜索方向 d_k 。
2. 求解 α_k 满足上述优化问题。
3. 更新 $x_{k+1} = x_k + \alpha_k d_k$ 。

0.5.4 回溯直线搜索 (Backtracking Line Search)

定义：回溯直线搜索是一种启发式方法，通过逐步减少步长 α ，找到一个满足 Wolfe 条件的步长：

$$f(x_k + \alpha d_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^\top d_k,$$

其中 $c_1 \in (0, 1)$ 是常数。**流程：**

1. 初始化 $\alpha = \alpha_0$ 和缩放因子 $\beta \in (0, 1)$ 。
2. 逐步减小 α : $\alpha \leftarrow \beta \alpha$ ，直到满足 Wolfe 条件。
3. 更新 $x_{k+1} = x_k + \alpha d_k$ 。

0.5.5 梯度下降法 (Gradient Descent)

定义：梯度下降法使用负梯度方向作为搜索方向 $d_k = -\nabla f(x_k)$ ，通过调整步长 α_k 进行迭代。**流程：**

1. 确定当前点 x_k 。
2. 计算搜索方向 $d_k = -\nabla f(x_k)$ 。
3. 使用直线搜索方法确定步长 α_k 。
4. 更新 $x_{k+1} = x_k + \alpha_k d_k$ 。

0.5.6 最速下降法 (Steepest Descent)

定义：最速下降法是梯度下降法的特例，步长 α_k 是通过精确直线搜索确定的。

$$\Delta x_{nsd} = \operatorname{argmin}\{\nabla f(x)^T v \mid \|v\| \leq 1\}$$

流程：与梯度下降法类似，只是步长 α_k 采用精确直线搜索。

0.5.7 Newton 步径 (Newton Step)

定义：Newton 步径是基于二阶泰勒展开，利用 Hessian 矩阵 $\nabla^2 f(x_k)$ 和梯度 $\nabla f(x_k)$ 定义的搜索方向：

$$d_k = -(\nabla^2 f(x_k))^{-1} \nabla f(x_k).$$

如果函数 f 是二次的。那么 $x + \Delta x_{nt}$ 是精确最优解。**流程：**

1. 确定当前点 x_k 。
2. 计算 Hessian 矩阵 $\nabla^2 f(x_k)$ 和梯度 $\nabla f(x_k)$ 。
3. 求解方向 $d_k = -(\nabla^2 f(x_k))^{-1} \nabla f(x_k)$ 。
4. 使用直线搜索方法确定步长 α_k 。
5. 更新 $x_{k+1} = x_k + \alpha_k d_k$ 。
6. 计算 Newton 减量

$$\lambda(x) = (\Delta x_{nt}^T \nabla^2 f(x) \Delta x_{nt})^{1/2}$$

0.5.8 Newton 方法 (Newton's Method)

定义：Newton 方法是一种二阶优化方法，采用 Newton 步径作为更新方向，并通常使用固定步长 $\alpha_k = 1$ 。又称为阻尼 Newton 方法或者谨慎 Newton 方法 **流程：**

1. 确定当前点 x_k 。
2. 计算 Hessian 矩阵 $\nabla^2 f(x_k)$ 和梯度 $\nabla f(x_k)$ 。
3. 求解更新公式：

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k).$$

0.5.9 方法之间的区别

1. 方向计算：

- 梯度下降法和最速下降法使用负梯度方向。
- Newton 方法使用二阶信息构造的方向。

2. 步长选择：

- 精确直线搜索求解最优步长，回溯直线搜索通过试探找到满足条件的步长。
- 最速下降法采用精确直线搜索，而梯度下降法可以结合回溯直线搜索。
- Newton 方法通常使用固定步长 $\alpha_k = 1$ 。

3. 收敛速度：

- 梯度下降法和最速下降法为一阶方法，收敛较慢。
- Newton 方法为二阶方法，收敛速度快（在问题条件适当时）。

4. 计算复杂度：

- Newton 方法需要计算 Hessian 矩阵，计算复杂度较高。
- 梯度下降法和最速下降法只需计算梯度，计算复杂度较低。

0.6 注意事项

0.6.1 纰漏

1. 一个既凸又凹的函数在进行非负加权和时可以作为既凸又凹的；若凸函数为负后是凹的，那么视之为凹
2. 判断矩阵正定/负定往往有两种简单的方法：主子式与特征值
3. t^α 往往是凹函数若有 $\alpha < 1$
4. 欧几里得球与椭球中 $P^{1/2} = A$
5. 常见的对数凹-凸函数：指数函数（对数凸与凹），仿射函数（对数凹函数）
6. 注意上境图与下水平集为 $f(x) \leq t$ 与 $f(x) \leq \alpha$ 。函数为凸当且仅当上境图是凸集。函数为拟凸若下水平集是凸集，但不一定凸。

7. 如果 $f_i(x, y)$ 关于 x 是凸函数, 那么其 \max, \sup, \inf ($y \in A$) 也是凸函数, 但没有对 \min 声明, 故对分片线性函数 $a_i^T x$ 的最小不一定保凸
8. 互补松弛条件仅在强对偶性成立时成立, 同理 KKT 条件。这两者是必须成立。而 Slater 条件是用于确保强对偶性成立的 (前提是原问题是凸问题)。如果原问题是凸问题, 那么满足 KKT 的点同时也是原问题的最优解
9. 关于凸函数的解答题, 首要说明凸函数的定义域是凸的
10. 关于凸优化中, 要声明下标从几到几
11. 对偶函数是凹函数, 对偶问题是凸优化问题
12. Δx 不是某个具体的 $\|x^{k+1} - x^k\|$, 而代表一个搜索方向, 比如可能为 $-\nabla f(x)$

o.6.2 例子概述

1. 射线 $\{x + \theta v | \theta \geq 0\}$ 不是仿射的, 除非经过原点
2. 线性矩阵不等式和有序线性不等式 ($a^T x = x_1 a_1 + x_2 a_2 + \dots + x_n a_n$)
3. 线性分式函数由透视函数和仿射函数复合而来, 其中 $g(x) = [A, c^T]^T x + [b, d]^T$ 是仿射函数, 自然 P 是透视函数
4. 正常锥 (广义不等式) 的简易例子: 非负象限、半正定锥
5. 对偶锥的例子: 对偶锥是其正交补; 非负象限; 半正定锥; 范数的对偶
6. 逐点最大的例子: 分片线性 $\max_i (a_i^T x + b_i)$
7. 共轭函数 (我的亲娘), 搞定了
8. 拟凸函数例子: $\log x$, 上取整 $\inf\{z | z \geq x\}$ 是拟线性, $x_1 x_2$ 是拟凹函数
9. 最优性条件例子: 无约束 $\nabla f_0(x)^T$, 只含等式约束 $\nabla f_0(x) + A^T v = 0$, 非负象限中的极小化 $x_i (\nabla f_0(x))_i = 0$

条件	凸问题要求	保证的性质	说明
KKT 条件	否	局部最优解的必要条件（一般问题）	原问题为凸时，KKT 是全局最优的充要条件。
Slater 条件	是	强对偶性，KKT 充分性	是凸问题强对偶性的充分条件。
互补松弛条件	否	局部最优解的必要条件（一般问题）	原问题为凸时，是全局最优的充要条件之一。
强对偶性	是	$p^* = d^*$	Slater 条件保证凸问题中强对偶性成立。

Table 1: KKT、Slater、互补松弛、强对偶性之间的关系

常见矩阵求导规则

一、 \mathbf{x} 为向量的常见规则

1. 标量对向量求导：若 $f = \mathbf{x}^T \mathbf{A} \mathbf{x}$ ，其中 \mathbf{A} 是对称矩阵，则

$$\frac{\partial f}{\partial \mathbf{x}} = 2\mathbf{A}\mathbf{x}.$$

2. 标量对向量求导（线性形式）：若 $f = \mathbf{b}^T \mathbf{x}$ ，其中 \mathbf{b} 是常向量，则

$$\frac{\partial f}{\partial \mathbf{x}} = \mathbf{b}.$$

3. 标量对向量求导（内积形式）：若 $f = \|\mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{x}$ ，则

$$\frac{\partial f}{\partial \mathbf{x}} = 2\mathbf{x}.$$

二、 \mathbf{X} 为矩阵的常见规则

1. 矩阵对矩阵求导：若 $f = \text{tr}(\mathbf{X}^T \mathbf{A})$ ，其中 \mathbf{A} 是常矩阵，则

$$\frac{\partial f}{\partial \mathbf{X}} = \mathbf{A}.$$

2. 矩阵的 Frobenius 范数：若 $f = \|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^T \mathbf{X})$ ，则

$$\frac{\partial f}{\partial \mathbf{X}} = 2\mathbf{X}.$$

3. 矩阵对矩阵的乘积求导：若 $f = \mathbf{X}\mathbf{Y}$ ，其中 \mathbf{X} 和 \mathbf{Y} 是矩阵，则

$$\frac{\partial(\mathbf{X}\mathbf{Y})}{\partial \mathbf{X}} = \mathbf{Y}^T.$$

4. 矩阵对行列式求导：若 $f = \det(\mathbf{X})$ ，其中 \mathbf{X} 是方阵，则

$$\frac{\partial \det(\mathbf{X})}{\partial \mathbf{X}} = \mathbf{X}^{-1} \mathbf{X}^T.$$